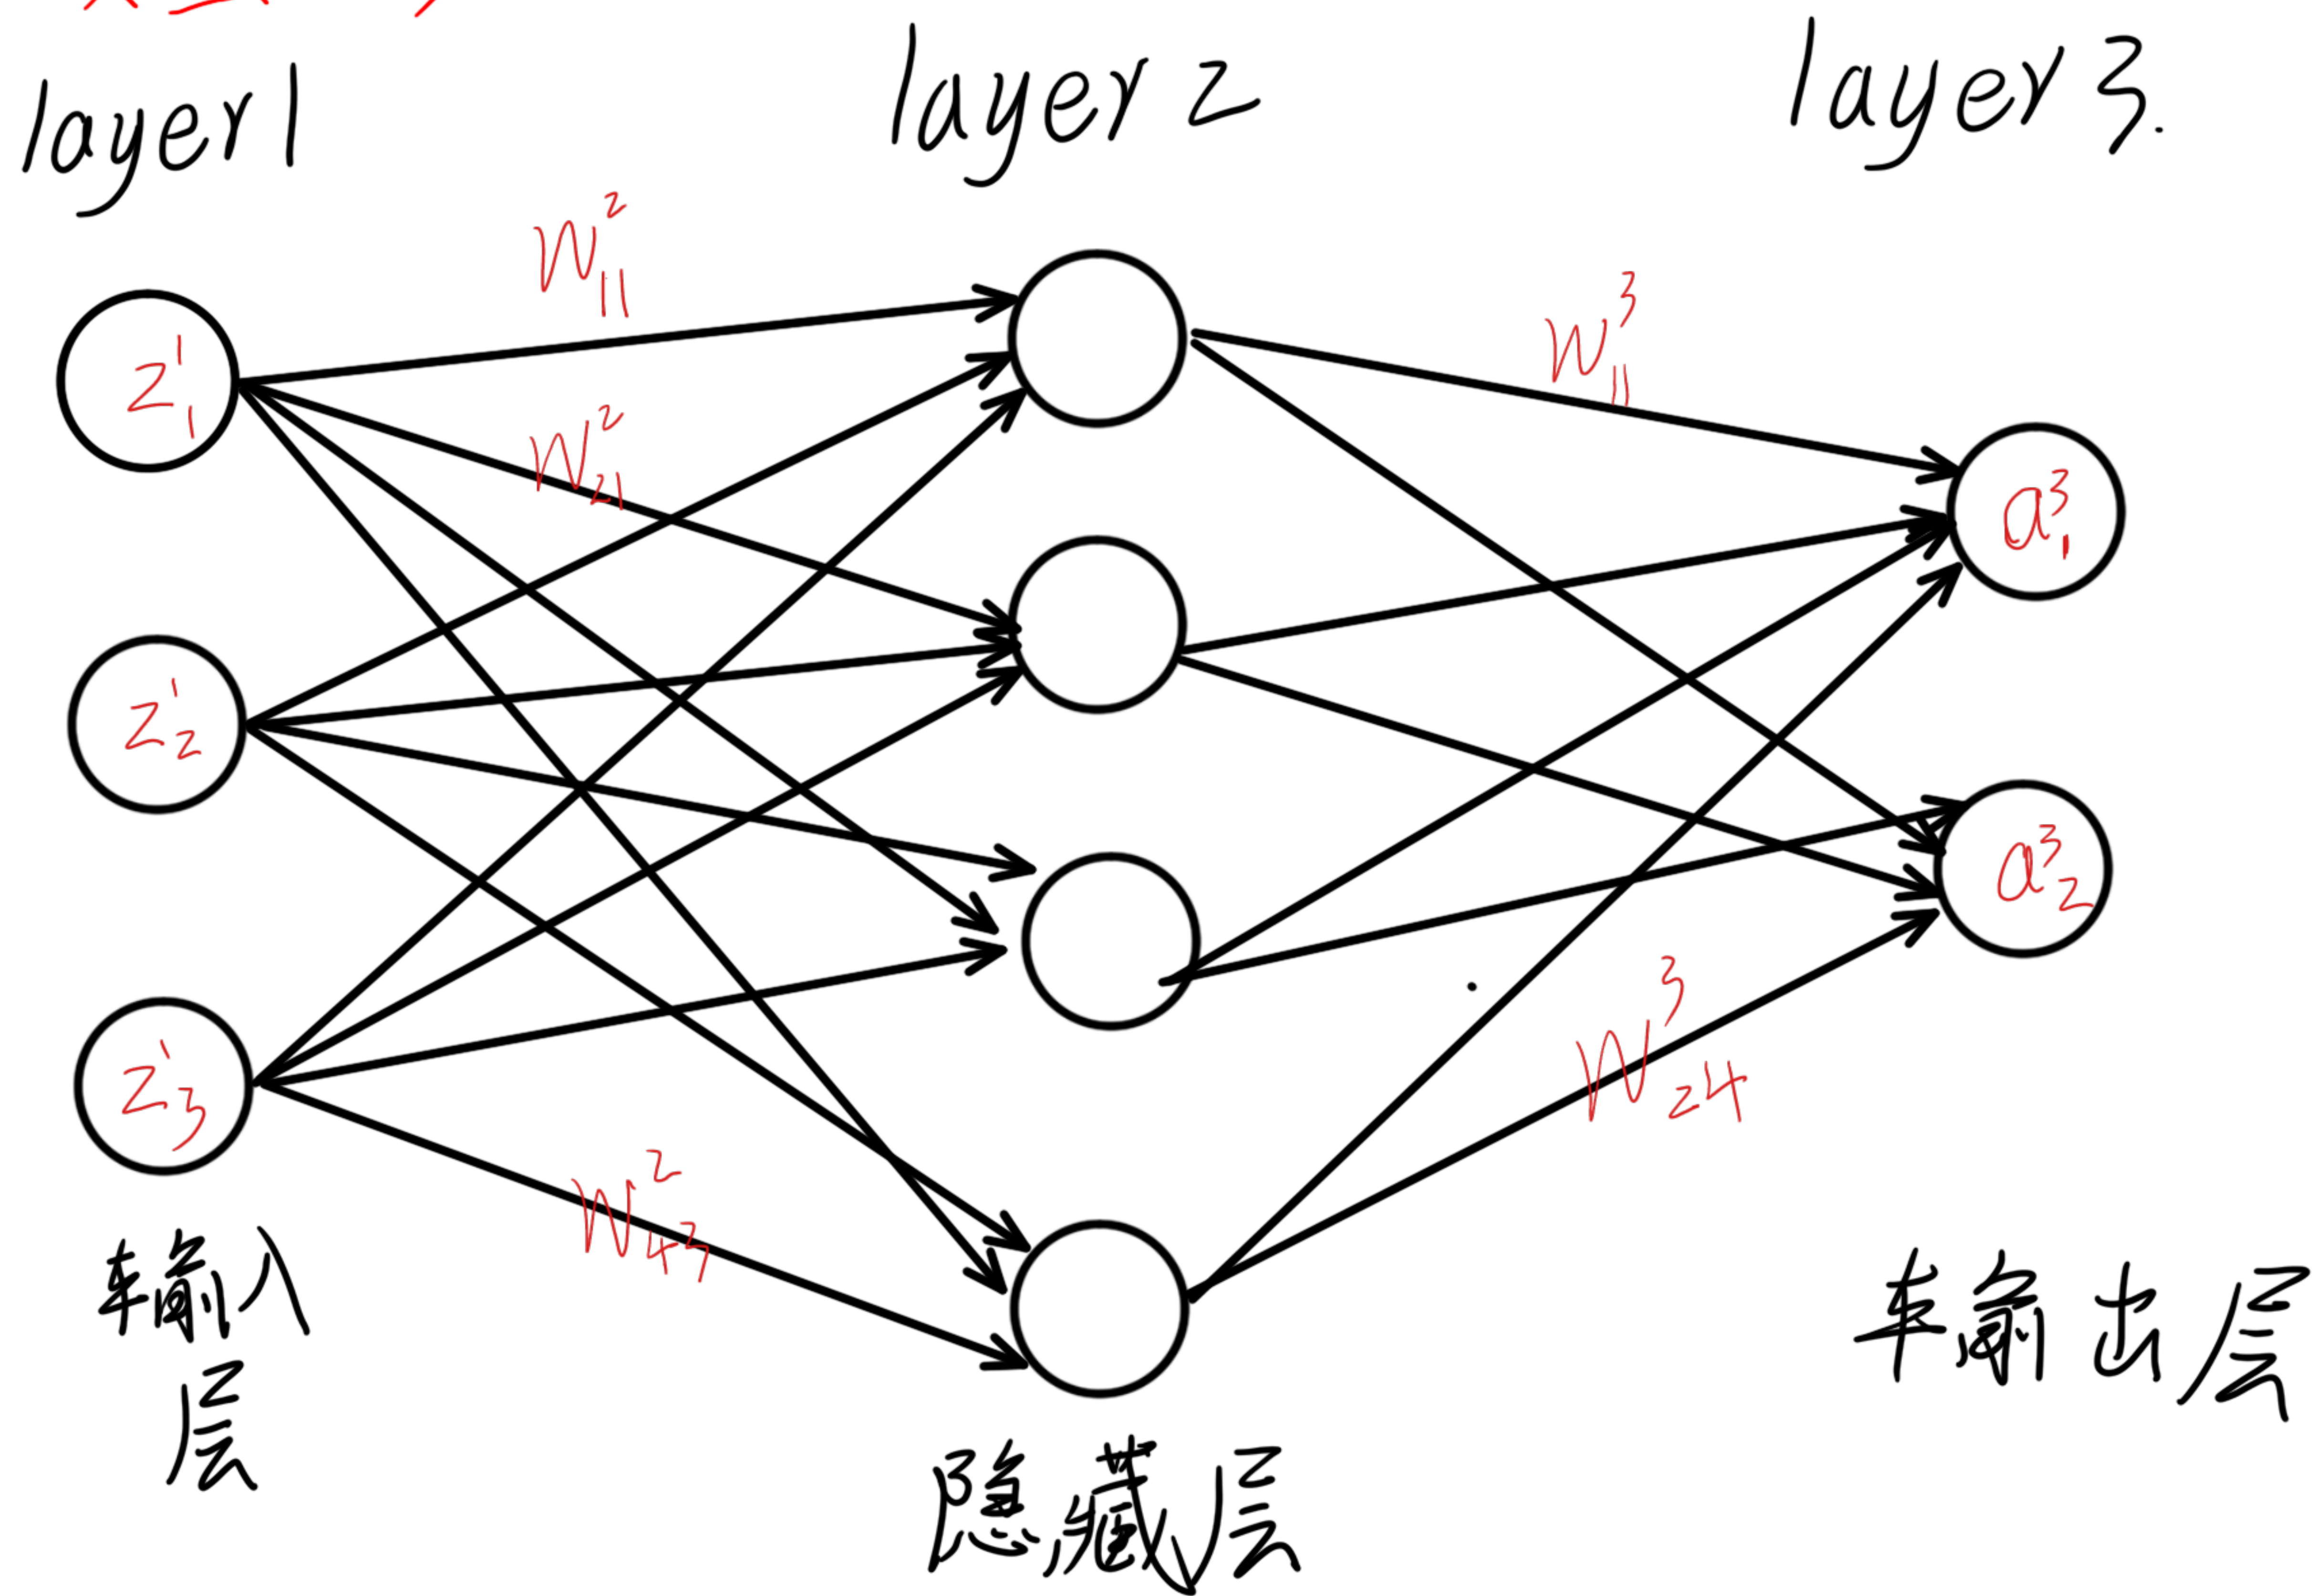


# 反向传播推导

## 1. 变量定义





上图是一个三层神经网络，对变量进行定义：

$w_{jk}^l$  表示第  $(l-1)$  层的第  $k$  个神经元连接到第  $l$  层第  $j$  个神经元的权重。

$b_j^l$  表示第  $l$  层第  $j$  个神经元的偏置。

$z_j^l$  表示第  $l$  层第  $j$  个神经元的输入，即： $z_j^l = \sum_k w_{jk}^l a_k^{l-1} + b_j^l$

$a_j^l$  表示第  $l$  层第  $j$  个神经元的输出，即： $a_j^l = G(\sum_k w_{jk}^l a_k^{l-1} + b_j^l)$

$G$  表示激活函数，常见的例如 sigmoid 函数、Relu 函数等。 $= G(z_j^l)$

## 2. 公式推导

首先，将第  $l$  层第  $j$  个神经元中产生的错误（即实际值与预测值之间的误差）定义为：

$$\delta_j^l = \frac{\partial C}{\partial z_j^l}$$



以一个输入样本为例进行说明, 此时损失函数与代价函数的均方误差表示形式均为:

$$C = \frac{1}{2} \sum_j (y_j - a_j^L)^2$$

$y_j$  表示真实值,  $a_j^L$  表示预测的输出值

公式 11 计算最后一层神经网络产生的误差)

$$\star \delta^L = \nabla_a C \odot G'(z^L) = \frac{\partial C}{\partial z^L} \odot \frac{\partial a^L}{\partial z^L}$$

其中,  $\odot$  表示 Hadamard 乘积, 用于矩阵或向量之间点对点的乘法运算,  $\nabla$  表示梯度运算符  $\Rightarrow$  例:  $f = [f_1, f_2, \dots, f_m]$   $x = [x_1, x_2, \dots, x_n]$

公式一推导过程:

$$\therefore \delta_j^L = \frac{\partial C}{\partial z_j^L} = \frac{\partial C}{\partial a_j^L} \cdot \frac{\partial a_j^L}{\partial z_j^L}$$

$$\nabla_x f = \begin{bmatrix} \frac{\partial f_1}{\partial x_1}, \frac{\partial f_1}{\partial x_2}, \dots, \frac{\partial f_1}{\partial x_n} \\ \vdots \\ \frac{\partial f_m}{\partial x_1}, \frac{\partial f_m}{\partial x_2}, \dots, \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$



$$\therefore \delta^L = \frac{\partial L}{\partial z^L} \odot \frac{\partial a^L}{\partial z^L} = \nabla_a C \odot g'(z^L)$$

公式 2 (由后向前, 计算每一层神经网络产生的误差):

$$\star \delta^L = (C W^{L+1})^T \delta^{L+1} \odot g'(z^L) \quad (T \text{ 表示矩阵转置运算})$$

推导过程:

$$\begin{aligned} \therefore \delta_j^L &= \frac{\partial L}{\partial z_j^L} = \sum_k \frac{\partial L}{\partial z_k^{L+1}} \cdot \frac{\partial z_k^{L+1}}{\partial a_j^L} \cdot \frac{\partial a_j^L}{\partial z_j^L} \\ &= \sum_k \delta_k^{L+1} \cdot \frac{\partial (w_{kj}^{L+1} a_j^L + b_k^{L+1})}{\partial a_j^L} \cdot g'(z_j^L) \\ &= \sum_k \delta_k^{L+1} \cdot w_{kj}^{L+1} \cdot g'(z_j^L) \end{aligned}$$

$$\therefore \delta^L = (C W^{L+1})^T \delta^{L+1} \odot g'(z^L)$$



公式3 (计算权重梯度):

$$\star \frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l$$

推导过程:

$$\frac{\partial C}{\partial w_{jk}^l} = \frac{\partial C}{\partial z_j^l} \cdot \frac{\partial z_j^l}{\partial w_{jk}^l} = \delta_j^l \cdot \frac{\partial (w_{jk}^l a_k^{l-1} + b_j^l)}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l$$

公式4 (计算偏置的梯度):

$$\star \frac{\partial C}{\partial b_j^l} = \delta_j^l$$

推导过程:

$$\frac{\partial C}{\partial b_j^l} = \frac{\partial C}{\partial z_j^l} \cdot \frac{\partial z_j^l}{\partial b_j^l} = \delta_j^l \cdot \frac{\partial (w_{jk}^l a_k^{l-1} + b_j^l)}{\partial b_j^l} = \delta_j^l$$

## 更新权重和偏置

设学习率为  $\eta$

$$(w_{jk}^L)_{\text{新}} = w_{jk}^L - \eta \cdot \frac{\partial C}{\partial w_{jk}^L} = w_{jk}^L - \eta a_k^{L-1} \delta_j^L$$

$$(b_j^L)_{\text{新}} = b_j^L - \eta \cdot \frac{\partial C}{\partial b_j^L} = b_j^L - \eta \delta_j^L$$

★ 总结：四个公式：

$$\textcircled{1} \quad \delta^L = \nabla_a C \odot \sigma'(z^L) = \frac{\partial C}{\partial z^L} \odot \frac{\partial a^L}{\partial z^L}$$

$$\textcircled{2} \quad \delta^L = (W^{L+1})^T \delta^{L+1} \odot \sigma'(z^L)$$

$$\textcircled{3} \quad \frac{\partial C}{\partial w_{jk}^L} = a_k^{L-1} \delta_j^L$$



$$\textcircled{4} \quad \frac{\partial c}{\partial b_j^L} = \delta_j^L.$$